

Reporte Entrega 2

Curso: Aprendizaje de Máquina Aplicado (ST1613/ST1631), EAFIT, 2026-1. **Equipo:** David Vélez · Daniela Villamizar · Jaymar Murillo.

Metodología

Corrección de leakage de E1

En la primera auditoría de E2, se detectó una fuga de datos importante en el split de E1: el particionamiento aleatorio 80/20 posibilitaba que temas del mismo artista aparecieran a la vez en train y test. Como el conjunto de datos tiene artistas con un máximo de 260 canciones, el modelo no lograba aprender a generalizar para nuevos artistas, sino que se enfocaba en identificar la firma acústica de artistas previamente conocidos.

Corrección: Se sustituyó `train_test_split` por `StratifiedGroupKFold(n_splits=5, shuffle=True, random_state=42)`, el cual fue agrupado de acuerdo con la columna `artists`. El primer fold (aproximadamente el 20%) funciona como holdout, mientras que los otros cuatro constituyen la muestra de entrenamiento. Se ha verificado que no hay superposición de artistas en **0** entre todos los conjuntos.

Pipeline de preprocesamiento

Idéntico al de E1, encapsulado en `sklearn.Pipeline`:

- `StandardScaler` sobre las 10 features numéricas.
- `OneHotEncoder(handle_unknown='ignore')` sobre las 4 features categóricas (`key`, `mode`, `time_signature`, `explicit`).
- El preprocesador se ajusta exclusivamente sobre los datos de entrenamiento de cada fold.

Validación cruzada interna

Sobre el 80% de train se aplicó `StratifiedGroupKFold(n_splits=5)` agrupado por artista, generando 5 particiones para comparar modelos. Se evaluaron 4 métricas por fold: `macro_f1` (primaria), `accuracy`, `balanced_accuracy`, `top3_accuracy`.

Configuración experimental

Modelos evaluados

Modelo	Familia	Hiperparámetros usados
<code>LogisticRegression</code>	Lineal	<code>max_iter=2000</code> , <code>C=1.0</code> (por defecto), <code>solver='lbfgs'</code>
<code>RandomForestClassifier</code>	Ensemble — bagging	<code>n_estimators=200</code> , <code>max_depth=None</code> , <code>n_jobs=-1</code>
<code>HistGradientBoostingClassifier</code>	Ensemble — boosting	<code>max_iter=200</code> , early stopping automático

Ningún modelo fue sometido a búsqueda de hiperparámetros en E2. Los valores usados son razonables pero no óptimos; el tuning sistemático queda para E3.

Partición de datos

Conjunto	Filas	Artistas únicos	Uso
Train (CV interno)	71,657	25,100	Comparación de modelos con 5-fold CV agrupado
Test (holdout)	17,914	6,286	Evaluación única del modelo seleccionado

Solapamiento de artistas entre train y test: **0**.

Recursos computacionales

Modelo	Tiempo de entrenamiento (train completo)
<code>LogisticRegression</code>	~12 s

RandomForestClassifier	~21 s
Modelo	Tiempo de entrenamiento (train completo)
HistGradientBoostingClassifier	~72 s

¿Qué modelos se compararon y por qué?

Se compararon tres familias de modelos supervisados de tabla:

Modelo	Familia	Justificación de inclusión
LogisticRegression	Lineal	Baseline real de E1. Referencia interpretable para medir la ganancia de los modelos no lineales.
RandomForestClassifier	Ensemble (bagging)	Captura interacciones no lineales entre features acústicas sin asumir estructura paramétrica. Robusto al ruido de etiqueta presente en géneros ambiguos.
HistGradientBoostingClassifier	Ensemble (boosting)	Construye árboles de forma secuencial corrigiendo errores previos. Desempeño comparable a XGBoost/LightGBM sin dependencias externas (incluido en scikit-learn).

La hipótesis de E1 era que `pop`, `rock` e `hip-hop` no son separables linealmente en el espacio de features de audio, lo que motivó incluir modelos capaces de aprender fronteras de decisión no lineales. Los hiperparámetros usados fueron razonables pero no optimizados (`n_estimators=200` para RF, `max_iter=200` para HGB); el tuning queda para E3.

¿Cómo se evitó el data leakage?

Problema detectado en E1

El split aleatorio 80/20 de E1 permitía que canciones del mismo artista cayeran simultáneamente en train y test. El dataset contiene 31,386 artistas únicos con un promedio de 2.85 tracks por artista; 11,265 artistas (35.9%) tienen dos o más canciones. Bajo un split aleatorio, esos artistas aparecen en ambos conjuntos y el modelo aprende la firma acústica del artista en lugar del género.

Impacto cuantificado: LogReg con split aleatorio obtuvo macro-F1 = 0.238; con split agrupado obtuvo 0.223. Prima de leakage: **+0.015 en macro-F1, +0.008 en accuracy**.

Corrección aplicada

Se reemplazó el split aleatorio por `StratifiedGroupKFold(n_splits=5, shuffle=True, random_state=42)` agrupado por la columna `artists`, tomando el primer fold como holdout (~20%). Esto garantiza:

- **Estratificación:** proporciones de las 16 clases preservadas en train y test.
- **Agrupamiento:** ningún artista aparece en ambos conjuntos.

Resultado verificado:

Conjunto	Filas	Artistas únicos	Solapamiento con el otro
Train	71,657	25,100	0
Test (holdout)	17,914	6,286	0

Para la validación cruzada interna sobre el 80% de train se aplicó el mismo esquema (`StratifiedGroupKFold` con 5 folds), verificando solapamiento nulo en cada fold:

Fold	Train	Validación	Solapamiento
1	57,337	14,320	0
2	57,307	14,350	0
3	57,337	14,320	0
4	57,335	14,322	0
5	57,312	14,345	0

El preprocesamiento (`StandardScaler` , `OneHotEncoder`) se mantiene dentro del `Pipeline` de scikit-learn, asegurando que ninguna transformación se ajusta con información del conjunto de validación o test.

¿Cuál familia parece más prometedora?

Resultados de validación cruzada (5 folds, agrupado por artista)

Modelo	macro-F1	accuracy	balanced acc.	top-3 acc.
logreg	0.234 ± 0.004	0.361 ± 0.008	0.250 ± 0.005	0.628 ± 0.010
random_forest	0.320 ± 0.005	0.432 ± 0.006	0.325 ± 0.005	0.692 ± 0.008
hist_gb	0.328 ± 0.007	0.426 ± 0.007	0.327 ± 0.007	0.690 ± 0.008

Tests estadísticos pareados (t-test relacionado + corrección de Bonferroni)

Comparación	Cohen's d	p (Bonferroni)	Conclusión
logreg vs random_forest	-10.23	0.0001	Diferencia significativa
logreg vs hist_gb	-10.93	0.0001	Diferencia significativa
random_forest vs hist_gb	-1.16	0.181	No significativa

Evaluación final en holdout (17,914 filas, nunca vistas durante CV)

`HistGradientBoostingClassifier` re-entrenado sobre el 80% completo:

Métrica	Holdout	CV media	Δ
macro-F1	0.339	0.328	+0.012
accuracy	0.433	0.426	+0.007
balanced accuracy	0.332	0.327	+0.005
top-3 accuracy	0.692	0.690	+0.001

El delta positivo y pequeño descarta sobreajuste al CV. El modelo generaliza al menos tan bien sobre el holdout como sobre los folds internos.

Familia seleccionada: los ensembles de árboles (boosting/bagging), con `HistGradientBoostingClassifier` como modelo provisional para E3 por tener el mayor macro-F1 medio en CV (0.328 vs 0.320 de Random Forest). La diferencia entre ambos no es estadísticamente significativa, por lo que el ranking podría cambiar con tuning sistemático.

Análisis de errores por clase (holdout, HGB)

Clase	F1	Patrón de error
electronic	0.620	Bien separada. Confusión menor con rock.
metal	0.604	Bien separada. Confusión menor con rock.
ambient	0.532	Alta acousticness la distingue bien.
pop	0.111	Precision baja (0.219): el modelo predice pop cuando en realidad es otra clase.
hip-hop	0.079	Recall muy bajo (0.049): casi nunca detectada correctamente.

Clase	F1	Alta precision (0.571) pero recall bajísimo (0.117): 103 ejemplos en holdout, modelo lo subdetecta.
	0.194	Patron de error

Las clases con mejor F1 coinciden con las que en el EDA ocupaban regiones acústicas extremas o claramente diferenciadas. Las clases con peor F1 (`pop` , `hip-hop` , `soul-funk`) comparten el espacio central de features con `rock` y `latin` , con poca separabilidad estructural a partir del audio solo.

Desbalance de clases

La razón entre la clase mayoritaria (electronic, ~2,978 en holdout) y la minoritaria (jazz, ~103) es 29:1. El modelo tiende a subdetectar clases pequeñas (`jazz` , `other`) en favor de clases grandes. Para E3 se evaluará `class_weight='balanced'` dentro del pipeline agrupado para no introducir leakage en el rebalanceo.

¿Qué limitaciones siguen abiertas?

1. Sin tuning de hiperparámetros

Los tres modelos se corrieron con valores por defecto o razonables. Los parámetros óptimos de `n_estimators` , `max_depth` , `learning_rate` , `min_samples_leaf` , etc. pueden cambiar el ranking entre Random Forest y HGB. Esto se abordará en E3 con `HalvingRandomSearchCV` agrupado por artista.

2. Poder estadístico limitado (5 folds)

Con solo 5 observaciones por modelo, el test de Wilcoxon no puede ser significativo a $\alpha = 0.05$ para ninguna comparación (p mínimo alcanzable = 0.0625). El t-test paramétrico sí detectó diferencias logreg vs ensembles, pero la comparación entre Random Forest y HGB queda sin resolver estadísticamente. Aumentar a `RepeatedStratifiedGroupKFold(n_splits=5, n_repeats=10)` elevaría el poder a costa de ~10× tiempo de cómputo.

3. Sin rebalanceo ni ajuste de umbral

Las clases pequeñas (`jazz` , `hip-hop` , `other`) son sistemáticamente subdetectadas. No se exploró `class_weight='balanced'` , SMOTE ni umbral de decisión por clase. El rebalanceo debe aplicarse estrictamente dentro de cada fold para no filtrar información del conjunto de validación.

4. Sin interpretación de features

No se realizó análisis de importancia de variables ni SHAP. Se desconoce qué features contribuyen más a cada decisión y en qué regiones del espacio el modelo falla estructuralmente. Esto queda para E3.

5. Clases acústicamente ambiguas

`pop` , `hip-hop` y `soul-funk` presentan $F1 < 0.13$ incluso con el mejor modelo. Parte del problema puede ser estructural: estas clases no tienen un perfil acústico único; el género está determinado en gran parte por factores extrasonoros (mercado, época, idioma). Una posible solución para E3 es evaluar si fusionar `soul-funk` con `hip-hop` o redefinir los límites del mapeo mejora la separabilidad.

6. Asian-pop vs pop

La clase `asian-pop` ($F1 = 0.376$) se creó para capturar j-pop, k-pop y cantopop, que comparten estructura con pop occidental pero tienen perfil acústico propio. Si el modelo final de E3 no logra separarla de `pop` con SHAP, se reconsiderará su fusión.

Discusión técnica

Salto entre modelo lineal y ensembles

La diferencia de ~9 pts de macro-F1 entre LogReg y los ensembles ($|Cohen's d| > 10$) valida la hipótesis planteada en E1: el espacio de features de audio contiene interacciones no lineales que el modelo lineal no puede capturar. El caso más claro es `pop` y `hip-hop` , que pasaron de $F1 = 0.000$ (LogReg) a $F1 = 0.111$ y 0.079 (HGB), evidenciando que las fronteras de decisión en el espacio central del dataset son no lineales por naturaleza.

Empate estadístico entre Random Forest e HistGradientBoosting

La diferencia de 0.0075 en macro-F1 entre los dos ensembles no alcanza significancia estadística ($p = 0.181$ post-Bonferroni). Con solo 5 folds el test tiene poder limitado, pero los intervalos de confianza al 95% se solapan parcialmente ([0.3154, 0.3241] vs [0.3214, 0.3327]), lo que confirma que la diferencia, si existe, es pequeña. Esto implica que el ranking puede invertirse con hiperparámetros optimizados.

Análisis del desbalance

La ratio 29:1 entre la clase más frecuente (electronic) y la más rara (jazz) afecta principalmente el recall de las clases pequeñas. `jazz` presenta la mayor asimetría precision/recall: $0.571 / 0.117$. El modelo es preciso cuando predice jazz, pero raramente lo hace. Esto sugiere que el umbral de decisión de jazz podría bajarse para aumentar recall a costa de precisión; la métrica macro-F1 respondería positivamente dado que el F1 actual de 0.194 tiene margen de mejora por el lado del recall.

Comparación de features con E1

El EDA de E1 anticipó que `acousticness` y `energy` serían las features más discriminativas. Los resultados del holdout confirman ese patrón: las clases con perfiles extremos en esas dos dimensiones (electronic, metal, ambient, classical) obtienen los mejores F1. Las clases que en el EDA mostraban superposición en el espacio central (pop, rock, hip-hop) siguen siendo las más difíciles.

Decisión provisional

Modelo seleccionado para E3: `HistGradientBoostingClassifier` con los hiperparámetros por defecto de E2 como punto de partida.

Justificación:

- Mayor macro-F1 medio en CV (0.328 vs 0.320 de Random Forest), aunque la diferencia no sea estadísticamente significativa.
- Confirmación sobre holdout: macro-F1 = 0.339, con delta positivo respecto al CV (+0.012), sin señales de sobreajuste.
- Los deltas de todas las métricas entre holdout y CV son pequeños y positivos, indicando buena generalización.

Esta decisión es provisional. Queda sujeta a revisión en E3 si:

- El tuning sistemático con `HalvingRandomSearchCV` invierte el ranking entre HGB y Random Forest.
- El promedio de probabilidades (stacking) entre ambos modelos supera a cualquiera individualmente.
- El análisis SHAP revela que algún modelo es más interpretable sin sacrificar desempeño.

Referencia de avance:

Etapas	Modelos	macro-F1
E1 Dummy	DummyClassifier	0.063
E1 Baseline	LogisticRegression	0.223
E2 Seleccionado	HistGradientBoosting	0.339

El modelo provisional supera al baseline de E1 en **+0.116 pts de macro-F1** (+52% relativo) y al dummy en un factor de **5.4x**.